

UNIVERSIDADE VIRTUAL DO ESTADO DE SÃO PAULO

Ademário Silva Mascarenhas
Alexsander da Silva Fernandes
Lucas Baldoino Santos
Marcos da Silva
Michele Jeremias da Silva Santos
Rafael Gonçalves Martins
Raul Kelmani Ribeiro França Junior
Rodrigo Felipe Nunes de Vasconcelos

Plataforma Analítica para Apoio à Tomada de Decisão em Investimentos de
Mídia Digital no Contexto Educacional

São Paulo - SP
2026

UNIVERSIDADE VIRTUAL DO ESTADO DE SÃO PAULO

Plataforma Analítica para Apoio à Tomada de Decisão em Investimentos de Mídia Digital no Contexto Educacional

Relatório Técnico-Científico apresentado na disciplina de Projeto Integrador IV para o curso de Ciência de Dados e Engenharia da Computação da Universidade Virtual do Estado de São Paulo (UNIVESP).

São Paulo - SP
2026

MASCARENHAS, Ademario Silva; FERNANDES, Alessander da Silva; SANTOS, Lucas Balduino; SILVA, Marcos da; SANTOS, Michele Jeremias da Silva; MARTINS, Rafael Gonçalves; FRANÇA JUNIOR, Raul Kelmani Ribeiro; VASCONCELOS, Rodrigo Felipe Nunes de. Plataforma Analítica para Apoio à Tomada de Decisão em Investimentos de Mídia Digital no Contexto Educacional. Ciência de Dados e Engenharia da Computação – **Universidade Virtual do Estado de São Paulo**. Tutor: Letícia Vieira Santos. Polo UniCEU Aricanduva, Polo UniCEU Jaçanã, Polo UniCEU Rosa da China, Polo UniCEU São Rafael, 2026.

RESUMO

Este trabalho investiga como organizar e apresentar dados históricos de investimentos em mídia digital para apoiar a tomada de decisão da gestão de uma instituição de ensino, cujos registros de investimento e desempenho de campanhas permanecem dispersos entre fontes distintas, dificultando a comparação de resultados e a distribuição do orçamento de marketing.

O objetivo geral é desenvolver e aplicar métodos de análise de dados e aprendizagem de máquina sobre um conjunto histórico de investimentos em mídia digital, produzindo indicadores que apoiem a interpretação dos resultados, comunicados por meio de uma plataforma web.

A metodologia combina uma etapa quantitativa, voltada à consolidação e ao cálculo de indicadores por rotinas determinísticas, com uma etapa qualitativa, orientada por Design Thinking, para levantar necessidades junto à instituição parceira e validar o protótipo com seus profissionais; de forma complementar e experimental, avalia-se o treinamento de um modelo supervisionado sobre relatórios de conteúdo orgânico da Meta, com IA agêntica empregada apenas como camada auxiliar de interpretação, sob supervisão humana.

Como resultados preliminares, foram definidos o problema, o escopo, a arquitetura analítica em três camadas e os requisitos de rastreabilidade e confidencialidade dos dados, permanecendo pendentes a construção da versão executável do protótipo e sua avaliação com a comunidade participante.

Espera-se com esse estudo poder ser concluído que a consolidação de dados dispersos em indicadores comparáveis, associada a uma camada opcional de aprendizagem de máquina, tende a oferecer suporte mais consistente às decisões de investimento em mídia digital no contexto educacional.

PALAVRAS-CHAVE: Marketing digital; Análise de dados; Aprendizagem de máquina; Dashboard; Tomada de decisão.

LISTA DE ILUSTRAÇÕES

- Figura 1: Quantidade de interessados entre os participantes da pesquisa em uma plataforma online para doação de livros;
- Figura 2: Tela inicial da aplicação;
- Figura 3: Regiões para doação;
- Figura 4: Como funciona o processo de doação.

SUMÁRIO

1 INTRODUÇÃO	6
2 DESENVOLVIMENTO	7
2.1 Objetivos	7
2.2 Justificativa e delimitação do problema	8
2.3 Fundamentação teórica	9
2.4 Metodologia	10
2.5 Resultados preliminares: solução inicial	11
REFERÊNCIAS	14

1 INTRODUÇÃO

O marketing digital articula canais, pontos de contato e interações que precisam ser examinados em conjunto ao longo da relação entre a organização e seus públicos (Kannan; Li, 2017). Quando campanhas são veiculadas em plataformas de anúncios, essas interações produzem registros de investimento, alcance, cliques e conversões. A aplicação de métodos de ciência de dados permite organizar tais registros e relacionar métricas de desempenho às decisões de marketing (Saura, 2021). No contexto educacional, painéis de indicadores podem apoiar gestores na compreensão de informações oriundas de diferentes sistemas e nos processos de tomada de decisão (Lemes; Dias; Oliveira, 2023).

Em campanhas digitais, métricas como investimento, conversão e retorno precisam ser interpretadas em relação aos objetivos organizacionais e às configurações de cada ação (Saura; Palos-Sánchez; Suárez, 2017). Na publicidade de busca, a possibilidade de combinar palavras-chave, lances, dispositivos e períodos torna insuficiente uma leitura baseada em um único total (Martins, 2019). Na instituição parceira, os registros de investimento e desempenho permanecem dispersos entre fontes distintas, com indicadores, unidades de medida e recortes temporais próprios (Grupo do Projeto Integrador, 2026). Essa fragmentação dificulta a comparação dos resultados entre canais e campanhas, a avaliação do retorno obtido e a decisão sobre como distribuir o orçamento de marketing (Grupo do Projeto Integrador, 2026). O problema que este trabalho enfrenta é, portanto, de natureza analítica antes de ser tecnológica: os dados existem, mas não se apresentam em forma que sustentem a decisão.

A ideia básica que orienta o trabalho é que esse conjunto disperso pode ser consolidado e submetido à análise de dados em escala. Indicadores calculados por regras determinísticas serão complementados por um modelo de aprendizagem de máquina treinado e avaliado a partir dos dados históricos; a interface web apresentará esses resultados de modo acompanhável pela gestão. O objeto deste trabalho é, assim, o desenvolvimento e a validação de uma análise de dados aplicada a investimentos em mídia digital no contexto educacional, comunicada por uma plataforma web e avaliada junto aos profissionais que respondem por essas decisões.

A escolha do tema decorre de uma necessidade real, manifestada por uma instituição de ensino privada da região metropolitana de São Paulo à qual o grupo teve acesso por intermédio de um de seus integrantes. Em conversa inicial, a gestora de marketing da

instituição expôs a dificuldade de estabelecer quanto deveria ser investido em tráfego pago e de avaliar se os valores praticados eram adequados aos objetivos institucionais. Em contato posterior com a direção, o grupo buscou identificar quais indicadores seriam mais relevantes para acompanhar os investimentos realizados e seus resultados ao longo do tempo. A receptividade da equipe e o acesso direto aos profissionais envolvidos indicaram condições favoráveis para desenvolver a solução e submetê-la à validação da própria comunidade participante.

Soma-se a essa demanda a composição interdisciplinar do grupo, que reúne estudantes dos cursos de Bacharelado em Ciência de Dados e Engenharia da Computação. Aplicações em Aprendizado de Máquina, Redes Neurais e Aprendizado Profundo fornecem o repertório de algoritmos, frameworks e modelos neurais pertinente à análise e à interpretação dos dados do projeto (UNIVESP, 2020). Visão Computacional amplia o repertório de aquisição, processamento e análise de dados visuais, enquanto Impactos da Computação na Sociedade orienta a reflexão sobre os aspectos éticos, sociais, legais e de governança de dados relacionados ao uso de inteligência artificial (UNIVESP, 2020; UNIVESP, 2026). Esses conteúdos são mobilizados como base de formação; o projeto não prevê o uso de imagens nem de dados sensíveis da instituição parceira.

2 DESENVOLVIMENTO

2.1 OBJETIVOS

O projeto busca desenvolver análise de dados em escala a partir de um conjunto de dados históricos existentes de investimentos em mídia digital, aplicando aprendizagem de máquina e preparando uma interface para visualização dos resultados. Essa finalidade corresponde explicitamente ao tema norteador da UNIVESP e articula o problema identificado junto à comunidade parceira (Grupo do Projeto Integrador, 2026).

Objetivo geral

Desenvolver e aplicar métodos de análise de dados e aprendizagem de máquina sobre dados históricos de investimentos em mídia digital de uma instituição de ensino, a fim de produzir indicadores e análises que apoiem a interpretação dos resultados e a tomada de decisão sobre a distribuição do orçamento de marketing. A plataforma web será o meio de apresentação desses resultados.

A consolidação dos dados e a organização de indicadores respondem à necessidade de tornar a avaliação de campanhas comparável e útil à gestão. No marketing digital, métricas e indicadores de desempenho apoiam a formulação de estratégias e permitem verificar se os resultados estão alinhados aos objetivos organizacionais (Saura; Palos-Sánchez; Suárez, 2017). Por essa razão, os dois primeiros objetivos específicos concentram-se em reunir os registros dispersos e estruturar indicadores que permitam analisar canais e campanhas.

O objetivo de aplicar análise de dados e aprendizagem de máquina não pressupõe que esses recursos substituam a decisão humana. Ele decorre do potencial da ciência de dados para extrair informações acionáveis de conjuntos extensos de dados no contexto do marketing digital e apoiar a tomada de decisão (Saura, 2021). No projeto, aprendizagem de máquina não será sinônimo de usar uma ferramenta de IA generativa: consistirá no treinamento e na avaliação de pelo menos um modelo supervisionado com exemplos históricos. Como recorte experimental proposto, o modelo poderá analisar relatórios de conteúdo orgânico da Meta para estimar ou classificar uma medida de desempenho previamente definida, desde que a base histórica tenha volume e variáveis adequados. A aprendizagem de máquina se caracteriza justamente pela melhoria do desempenho em uma tarefa a partir da experiência representada pelos dados (Jordan; Mitchell, 2015).

Os indicadores como investimento, impressões, cliques, custo por clique, taxa de conversão e retorno serão calculados por rotinas determinísticas, com entradas, parâmetros e resultados registráveis. Essa camada não será apresentada como aprendizagem de máquina; ela servirá de base comparável e reproduzível para a análise e para a avaliação do modelo preditivo (Peng, 2011). Na literatura de marketing, a aprendizagem de máquina é uma subárea da IA aplicada a grandes volumes de dados e a casos como apoio à decisão e impacto financeiro (De Mauro; Sestino; Bacconi, 2022).

A IA agêntica será empregada via linha de comando somente como camada auxiliar: poderá organizar a execução de cenários de simulação, propor explicações para indicadores e apoiar a revisão dos artefatos produzidos. Ela não treinará nem substituirá o modelo de aprendizagem de máquina. Agentes baseados em modelos de linguagem constituem uma arquitetura que combina o modelo a planejamento, memória e uso de ferramentas, mas o campo ainda apresenta desafios que exigem controles e avaliação humana (Wang et al., 2024). Portanto, as respostas dos agentes não serão tratadas como cálculo, evidência empírica ou decisão autônoma; cada cenário será calculado ou estimado pelas rotinas e modelos definidos pelo grupo e ficará sujeito à revisão humana.

O desenvolvimento da interface e a avaliação do protótipo decorrem da necessidade de converter a análise em informação compreensível para quem decide. No contexto educacional, dashboards podem apoiar gestores na compreensão de informações oriundas de diferentes sistemas e nos processos de tomada de decisão (Lemes; Dias; Oliveira, 2023). A avaliação com profissionais da instituição parceira será orientada por métodos de experiência do usuário, cuja literatura sistematiza técnicas para compreender necessidades e avaliar serviços de informação (Pinheiro; Dias, 2023).

Em decorrência dessas necessidades, foram definidos os seguintes objetivos específicos:

Objetivos específicos

- Identificar e organizar indicadores que permitam comparar o desempenho de canais e campanhas.
- Avaliar a viabilidade de preparar dados históricos de conteúdo orgânico da Meta, treinar e avaliar ao menos um modelo supervisionado de aprendizagem de máquina

para estimar ou classificar uma medida de desempenho definida, comparando-o a uma referência determinística e registrando suas métricas de avaliação.

- Empregar IA agêntica via linha de comando como apoio controlado à formulação, execução e interpretação de cenários de simulação, sem substituir os cálculos determinísticos, o modelo de aprendizagem de máquina ou a revisão humana.
- Desenvolver uma interface web que apresente os indicadores de forma compreensível para a gestão.
- Avaliar a versão inicial do protótipo com profissionais da instituição parceira, registrando as contribuições recebidas para sua evolução.

2.2 JUSTIFICATIVA E DELIMITAÇÃO DO PROBLEMA

O problema de pesquisa foi identificado nas conversas iniciais com a gestora de marketing e a direção da instituição parceira. Os dados de investimento e desempenho das campanhas de mídia digital permanecem distribuídos em fontes distintas, o que dificulta comparar canais, avaliar o retorno das campanhas e decidir sobre a distribuição do orçamento de marketing (Grupo do Projeto Integrador, 2026). Diante desse contexto, a pesquisa é orientada pela seguinte questão: como organizar e apresentar os dados históricos de investimentos em mídia digital de modo a apoiar a tomada de decisão da gestão de uma instituição de ensino?

O problema vincula-se ao tema norteador da UNIVESP porque faz parte de um conjunto de dados existente, demanda análise de dados em escala e aprendizagem de máquina para interpretá-lo e prevê uma interface web para tornar os resultados acompanháveis. A escolha de indicadores e métricas é necessária para avaliar a efetividade das estratégias de marketing digital e verificar sua aderência aos objetivos organizacionais (Saura; Palos-Sánchez; Suárez, 2017). A proposta, portanto, não se limita à criação de uma interface: busca converter dados dispersos em informação que possa sustentar uma decisão de gestão.

A relevância acadêmica decorre da aproximação entre ciência de dados, marketing digital e apoio à decisão. A literatura aponta que a ciência de dados pode extrair informações acionáveis de grandes conjuntos de dados nesse contexto, embora ainda existam lacunas sobre sua gestão e aplicação em estratégias de marketing (Saura, 2021). A relevância social e cultural está em desenvolver a solução a partir das necessidades expressas pelos profissionais da própria comunidade participante, preservando seu contexto de trabalho e submetendo a

versão inicial à sua avaliação (Grupo do Projeto Integrador, 2026). Espera-se, assim, contribuir para que a gestão acompanhe informações relevantes às suas decisões sem impor um modelo desvinculado da realidade institucional.

O escopo está limitado à consolidação, análise e visualização de dados históricos relacionados a campanhas de mídia paga e aos indicadores definidos com a instituição parceira. Não fazem parte do estudo a integração com contas reais de anúncios, CRM, sistemas acadêmicos ou outras bases operacionais, nem o tratamento de dados pessoais ou informações comerciais sensíveis. A solução será desenvolvida em ambiente acadêmico independente, com dados locais fictícios, preservando a confidencialidade da comunidade participante. A camada de IA agêntica receberá apenas esses dados locais e será acionada pela linha de comando do grupo. A escolha do modelo de linguagem será instrumental e poderá ser alterada sem modificar o método: resultados de simulações continuarão identificados como exploratórios e dependerão de cálculo determinístico e revisão humana.

2.3 FUNDAMENTAÇÃO TEÓRICA

Para promover uma perfeita articulação entre os termos centrais do projeto, a fundamentação adota três camadas distintas. A primeira é a análise determinística, formada por métricas e indicadores obtidos por regras explícitas. A segunda é a aprendizagem de máquina, entendida como treinamento e avaliação de modelos que aprendem padrões a partir de exemplos históricos e produzem estimativas para novas observações (Jordan; Mitchell, 2015). A terceira é a IA agêntica/generativa, utilizada somente como apoio controlado à organização e interpretação, sem ser apresentada como o método que aprende com os dados.

Essa distinção é particularmente necessária no marketing digital: a revisão de De Mauro, Sestino e Bacconi (2022) posiciona a aprendizagem de máquina como subárea da IA e identifica aplicações em marketing ligadas a apoio à decisão e impacto financeiro. Assim, a contribuição técnica prevista não é apenas uma interface nem uma explicação gerada por IA: inclui o planejamento e, caso a base histórica de conteúdo orgânico da Meta se mostre adequada, o treinamento e a avaliação de um modelo de aprendizagem de máquina. O modelo, a variável-alvo, as variáveis de entrada, o particionamento dos dados e as métricas de avaliação serão documentados na metodologia e nos resultados.

2.3.1 Marketing digital e decisão orientada por dados

O marketing digital pode ser compreendido como um conjunto integrado de atividades, canais e interações mediadas por tecnologias digitais, e não como a simples publicação de anúncios. Nessa perspectiva, a organização define objetivos, seleciona pontos de contato com seus públicos, acompanha as respostas obtidas e ajusta suas ações à luz dos resultados. Kannan e Li (2017) destacam justamente a necessidade de examinar o marketing digital de forma integrada, considerando os diferentes canais e as jornadas que conectam a organização aos seus públicos.

Para uma instituição de ensino, esse enquadramento aproxima os dados de mídia de uma decisão gerencial concreta: avaliar como os recursos de comunicação contribuem para os objetivos de captação definidos pela organização. Isso não autoriza concluir, sem evidência, que uma campanha causou uma matrícula. O que a análise poderá fazer é organizar os registros históricos disponíveis, identificar padrões de desempenho e apresentar evidências comparáveis sobre canais, campanhas, públicos e períodos, sempre dentro dos limites dos dados recebidos.

O uso de dados no marketing digital transforma registros operacionais — como investimento, exposição, interações e conversões registradas — em insumos para acompanhamento e decisão. Saura (2021) associa a aplicação de ciência de dados no marketing digital à análise de desempenho e à utilização de métricas para orientar ações. No escopo deste projeto, a interface web será o meio de visualização desses resultados; a contribuição central será a análise dos dados históricos e, em módulo experimental separado, a avaliação de aprendizagem de máquina sobre relatórios de conteúdo orgânico da Meta, se a base permitir uma avaliação metodologicamente válida.

Assim, a decisão orientada por dados será tratada como processo de apoio, e não como substituição do julgamento dos responsáveis da instituição. Os indicadores e as estimativas analíticas devem oferecer evidências para priorizar investigações e discutir a distribuição do orçamento, enquanto as decisões finais permanecem condicionadas ao contexto institucional, às metas de captação e às restrições identificadas pela comunidade externa.

2.3.2 Tráfego pago e campanhas de Ads

Tráfego pago, no escopo deste trabalho, corresponde às ações de comunicação em que a instituição investe recursos para veicular anúncios em plataformas digitais e direcionar usuários a um ponto de contato definido. A expressão não se confunde com todo o marketing digital: ela delimita a parcela das ações cuja veiculação produz registros de investimento e desempenho. O recorte empírico será formado exclusivamente pelos dados históricos de campanhas que a instituição parceira autorizar para uso acadêmico.

As campanhas de Ads oferecem diferentes possibilidades de configuração. No caso da publicidade de busca, por exemplo, é possível associar anúncios a palavras-chave e ajustar lances segundo fatores como dispositivo e período de veiculação (Martins, 2019). Essa variedade torna inadequada uma leitura que considere somente o total investido ou o total de cliques. A análise deverá observar as unidades efetivamente presentes na base — como canal, campanha, grupo/conjunto de anúncios, anúncio, palavra-chave ou período — sem presumir que todos esses campos estarão disponíveis.

O propósito da análise não será declarar, antecipadamente, qual campanha deve receber mais orçamento. Será organizar evidências para comparar exposição, interesse, conversão e custo em relação aos objetivos de captação definidos com a instituição. Em publicidade de busca paga, as decisões de lance e de orçamento são influenciadas pelo modo como as conversões são atribuídas aos elementos que antecedem a ação do usuário (Li et al., 2016). Por isso, a regra de atribuição registrada pela plataforma, quando disponível, será tratada como parte do contexto analítico e não como um detalhe técnico dispensável.

Desse modo, o tráfego pago constitui o domínio de aplicação da análise de dados em escala do PI e do motor determinístico de apoio a decisões de investimento. O experimento de aprendizagem de máquina será mantido como módulo separado, com possível recorte em relatórios de conteúdo orgânico da Meta, para não confundir estimativas preditivas com os cenários determinísticos de orçamento. A interface web terá a função de apresentar as evidências produzidas; ela não substitui a análise nem determina de forma autônoma as decisões de investimento.

2.3.3 Indicadores de Ads e tomada de decisão

Os indicadores serão calculados por regras determinísticas e usados em conjunto, evitando decisões baseadas em uma métrica isolada. Investimento, impressões e alcance descrevem a exposição; cliques e CTR avaliam a resposta inicial; CPC mostra o custo do tráfego; conversões e taxa de conversão aproximam o resultado de captação; CPA e retorno/ROAS apoiam a comparação entre o valor gerado e o recurso aplicado (Saura, 2021; Saura; Palos-Sánchez; Suárez, 2017).

Indicador ou combinação	Pergunta de decisão que orienta
Investimento, impressões e alcance	Onde houve entrega e exposição suficientes para justificar continuidade ou revisão da segmentação?
Cliques, CTR e CPC	Quais anúncios, públicos ou palavras-chave atraem interesse com custo compatível?
Conversões, taxa de conversão e CPA	Quais campanhas transformam interesse em ação desejada a um custo sustentável?
Receita/valor atribuído, investimento e ROAS/retorno	Como priorizar a distribuição do orçamento entre campanhas e canais?

A atribuição de conversões será declarada antes das comparações, pois a regra escolhida altera o crédito atribuído aos elementos da jornada e pode modificar decisões de lance, orçamento e retorno estimado (Li et al., 2016). Quando não houver receita ou valor de conversão confiável na base, o relatório não calculará ROAS como se fosse dado observado; usará conversões, taxa de conversão e CPA como indicadores disponíveis, registrando essa limitação.

2.3.4 Análise de dados em escala e apoio à tomada de decisão

A análise de dados em escala, neste projeto, começa pela organização de um conjunto histórico existente de registros de mídia paga. O objetivo não é acumular dados, mas

estabelecer um processo reprodutível para receber, identificar, padronizar, integrar e transformar os registros em uma base adequada à análise. Essa preparação é necessária para que comparações entre campanhas e períodos não sejam afetadas por nomes inconsistentes, formatos incompatíveis, valores ausentes, duplicações ou unidades de medida diferentes.

A qualidade desse processo é parte do resultado analítico. Foidl et al. (2024) identificam ingestão, integração, limpeza e transformação como etapas relevantes de pipelines de dados e associam problemas de qualidade a aspectos como tipos de dados, compatibilidade e rastreabilidade. No projeto, cada transformação relevante deverá ser documentada, de modo que um indicador ou uma estimativa possa ser relacionado à sua origem, ao período analisado e às regras aplicadas.

Essa documentação também permite distinguir, mera repetição, de uma análise verdadeiramente reprodutível. A reprodutibilidade exige que outro integrante consiga reconstruir o resultado a partir das mesmas entradas e condições de processamento (Peng, 2011). Por isso, o histórico de transformações, as fórmulas e os parâmetros comporão a evidência do resultado, e não apenas uma descrição auxiliar do desenvolvimento.

Após a preparação, a análise explorará os dados em seus níveis de agregação disponíveis para identificar distribuição de investimento, variações temporais, diferenças de desempenho e possíveis inconsistências a investigar. Esses achados não serão automaticamente convertidos em relações de causa e efeito. Eles funcionarão como evidências para a interpretação conjunta com a instituição e como base para as rotinas de indicadores. O eventual modelo de aprendizagem de máquina será avaliado em módulo próprio, com dados orgânicos da Meta e protocolo separado.

2.3.5 Aprendizagem de máquina aplicada ao marketing digital

A aprendizagem de máquina será empregada como método analítico distinto do cálculo de indicadores. Enquanto CTR, CPC, taxa de conversão e CPA resultam de fórmulas previamente definidas, um modelo de aprendizagem de máquina é treinado com exemplos históricos para reconhecer padrões e produzir uma estimativa para observações não usadas no treinamento. Jordan e Mitchell (2015) caracterizam esse campo pela melhoria do desempenho em uma tarefa a partir da experiência representada pelos dados.

No contexto do marketing, De Mauro, Sestino e Bacconi (2022) situam a aprendizagem de máquina como subárea da inteligência artificial e identificam aplicações ligadas ao apoio à decisão e ao impacto financeiro. Neste PI, o recorte experimental proposto é usar relatórios históricos de conteúdo orgânico da Meta, caso contenham volume e variáveis suficientes. A variável-alvo poderá ser uma medida de engajamento observada após a publicação ou uma classe de desempenho definida a partir dessa medida; a escolha dependerá da inspeção da base e será registrada antes do treinamento.

O método exigirá a descrição das variáveis de entrada, da variável-alvo, do particionamento entre treinamento e teste, do modelo ou modelos comparados e das métricas de avaliação. A qualidade de um modelo não será inferida apenas por produzir uma previsão aparentemente plausível: deverá ser avaliada em dados separados e confrontada com uma referência simples e reproduzível. Dessa forma, a aprendizagem de máquina complementar os indicadores determinísticos, sem substituí-los.

2.3.6 Visualização de dados e dashboards para apoio à gestão educacional

A visualização de dados é a camada pela qual os resultados analíticos se tornam acessíveis aos profissionais que participam da decisão. Um dashboard não deve apenas reunir gráficos: deve apresentar indicadores, comparações e recortes temporais de forma que o usuário possa compreender o que está sendo medido e formular perguntas sobre o desempenho das campanhas. Em instituições de ensino, Lemes, Dias e Oliveira (2023) identificam o uso de dashboards como recurso de apoio à tomada de decisão e à integração de informações provenientes de sistemas distintos.

Além da integração, a organização visual precisa corresponder à pergunta analítica apresentada. Padrões de design de dashboards ajudam a relacionar estrutura, interação e conteúdo, permitindo justificar porque determinada visão emprega comparação temporal, detalhamento, agrupamento ou destaque de exceções (Bach et al., 2023). O protótipo deverá, portanto, selecionar cada recurso visual por sua função na interpretação, e não apenas por disponibilidade técnica.

No protótipo, a interface web deverá apresentar os indicadores calculados, os filtros compatíveis com a base e, quando houver modelo validado, suas estimativas claramente

diferenciadas de valores observados. O desenho da visualização deverá preservar contexto: período, canal, unidade de análise, fórmula do indicador e limitações dos dados precisam estar disponíveis para interpretação. Assim, a interface não transformará uma estimativa em certeza nem ocultará a regra que originou uma métrica.

A avaliação com a comunidade externa verificará se as visualizações permitem compreender os resultados e discutir as decisões previstas. As sugestões recebidas serão registradas como evidências de adequação e melhoria do protótipo, sem afirmar que o dashboard, por si só, garante melhoria nas decisões ou nos resultados de captação.

2.3.7 Uso controlado de IA agêntica e supervisão humana

A IA agêntica será tratada como recurso auxiliar de organização e interação com ferramentas, e não como sinônimo de aprendizagem de máquina aplicada à base de campanhas. Agentes baseados em modelos de linguagem podem combinar componentes como planejamento, memória e uso de ferramentas; contudo, a área permanece em desenvolvimento e apresenta desafios de avaliação e confiabilidade (Wang et al., 2024). Essa característica impede que suas respostas sejam aceitas como evidência sem verificação.

No projeto, modelos de linguagem de alta capacidade poderão atuar como camada de interpretação assistida: organizar evidências, comparar cenários e formular explicações preliminares sobre indicadores e resultados já calculados. Essa atividade não será confundida com a inferência do modelo de aprendizagem de máquina. O agente não terá acesso a contas reais de anúncios, não executará alterações de orçamento e não definirá o modelo de aprendizagem de máquina sem validação do grupo. Dados sensíveis ou identificáveis não serão enviados a essa camada.

Para garantir rastreabilidade, a engenharia de memória/contexto do agente reunirá somente documentos versionados, dados confiáveis, fórmulas de indicadores, resultados do modelo e decisões já registradas. Toda explicação ou recomendação deverá indicar a evidência que a sustenta — dado, período, cálculo, resultado estimado ou referência bibliográfica — e será rejeitada quando criar métricas, resultados ou conclusões sem base verificável. A decisão final sobre a interpretação dos resultados, as recomendações e a evolução do protótipo permanecerão sob responsabilidade humana, em diálogo com a instituição parceira.

2.4 METODOLOGIA

O percurso metodológico combinará uma etapa quantitativa, voltada à preparação e à análise dos registros históricos, com uma etapa qualitativa, destinada a compreender as necessidades dos profissionais e avaliar a utilidade e a compreensão do protótipo. As duas etapas permanecerão articuladas: os dados delimitarão o que pode ser calculado ou estimado, enquanto a participação da comunidade indicará quais perguntas de gestão e formas de apresentação são relevantes. A descrição abaixo registra o procedimento planejado; atividades ainda não realizadas não são apresentadas como resultado.

2.4.1 Delineamento do projeto e participação da comunidade externa

O projeto possui caráter aplicado: parte de uma demanda apresentada pela instituição parceira e busca produzir uma solução analítica passível de ser discutida no contexto em que o problema foi identificado. O percurso combinará levantamento de necessidades, análise de dados históricos, construção de uma visualização e validação progressiva com os profissionais que participam das decisões de marketing. Essa aproximação é compatível com o uso de Design Thinking em pesquisas que articulam compreensão do problema, ideação e experimentação de soluções (Rosado; Dias, 2024).

Na etapa de ouvir, serão consolidados os registros das conversas já realizadas e levantadas as perguntas, restrições e prioridades dos profissionais envolvidos. Na etapa de criar, essas necessidades serão relacionadas aos campos disponíveis, às regras de cálculo e às alternativas de visualização, produzindo uma versão inicial da solução. Na etapa de prototipar e implementar, a interface será apresentada à comunidade para execução de tarefas de interpretação e coleta de observações. Cada passagem entre etapas deverá deixar evidências — registro da necessidade, decisão de projeto, versão do protótipo e contribuição recebida — para demonstrar como a escuta afetou a solução.

A participação da comunidade externa ocorrerá por meio de conversas, apresentação das leituras analíticas e coleta de sugestões sobre a utilidade e a compreensibilidade da solução. Somente atividades efetivamente realizadas serão registradas como evidências do processo. Enquanto uma conversa, visita ou validação não tiver ocorrido, ela será apresentada como etapa planejada, e não como resultado alcançado.

2.4.2 Arquitetura analítica de três camadas

O motor analítico adotará três camadas com escopos distintos. A primeira será a camada de conformidade, formada por regras de negócio e indicadores determinísticos que comparam valores observados a requisitos previamente declarados. A segunda realizará leituras agregadas do funil de captação e das matrículas, quando os períodos e os campos permitirem esse cruzamento. A terceira registrará os limites de atribuição individual, isto é, os casos em que as fontes disponíveis não permitem ligar uma ação de mídia, um contato e uma matrícula específica.

Essa separação impede que um resultado de regra seja apresentado como causalidade ou que uma correlação agregada seja tratada como atribuição por canal. Quando uma informação necessária não estiver disponível, o resultado será sinalizado como não verificável. A ausência de dados não será preenchida por estimativa silenciosa nem convertida em certeza analítica. A distinção entre métricas de desempenho, decisões de investimento e regras de atribuição é necessária porque a atribuição adotada altera a leitura de retorno e as decisões de orçamento (Saura, 2021; Li et al., 2016).

2.4.3 Fontes de dados, recortes temporais e confidencialidade

As análises utilizarão, conforme a disponibilidade autorizada, dados históricos de busca paga, mídia social, funil de captação, matrículas e conteúdo orgânico. Cada fonte terá seu período de referência e sua unidade de análise identificados antes de qualquer comparação. Métricas de fontes ou janelas temporais distintas não serão somadas ou comparadas como se representassem o mesmo fenômeno; por exemplo, conversão de busca, conversa iniciada, lead e matrícula permanecerão indicadores distintos. Essa precaução é coerente com a literatura de busca paga, na qual o crédito de conversão depende da estratégia de atribuição e pode alterar a interpretação do retorno (Li et al., 2016).

A coleta quantitativa será realizada a partir de arquivos ou exportações fornecidos de forma autorizada, mantidos no ambiente operacional e descritos por fonte, período, granularidade e campos disponíveis. Antes do cálculo dos indicadores, será produzido um inventário das fontes e um registro das transformações necessárias. A coleta qualitativa utilizará os registros das conversas e da avaliação orientada do protótipo, sem atribuir aos participantes afirmações

que não tenham sido efetivamente registradas. A análise quantitativa descreverá distribuições, variações temporais e diferenças de desempenho; a análise qualitativa organizará necessidades e observações por temas relacionados à compreensão, utilidade e melhoria da solução.

Os dados autorizados, o código operacional e os relatórios técnicos detalhados permanecerão no repositório real da solução. No ambiente acadêmico, serão usados apenas dados fictícios ou confiáveis, sem identificadores pessoais, credenciais, nomes de contas ou informações comerciais sensíveis. Essa delimitação permite discutir o método e demonstrar a interface sem expor a instituição parceira.

2.4.4 Preparação, governança e rastreabilidade dos dados

Os dados passarão por ingestão local, identificação da origem, normalização de nomes e formatos, verificação de tipos, tratamento explícito de valores ausentes e consolidação em artefatos versionados. Cada indicador deverá preservar a informação sobre fonte, período, unidade de análise e fórmula utilizada. Problemas de qualidade em pipelines podem ocorrer em etapas de ingestão, integração, limpeza e transformação, o que reforça a necessidade de documentar as regras aplicadas (Foidl et al., 2024).

Valores ausentes, incompatibilidades de período e falhas estruturais serão sinalizados no resultado; não serão convertidos silenciosamente em zero nem em estimativas. Essa regra permite distinguir um indicador efetivamente medido de um dado indisponível e possibilita a auditoria posterior das transformações realizadas.

2.4.5 Indicadores, regras de negócio e cenários determinísticos de investimento

Os indicadores serão calculados por rotinas determinísticas, com fórmulas e parâmetros registrados. Entre eles poderão estar investimentos, impressões, alcance, frequência, cliques, CTR, CPC, conversões, taxa de conversão, CPA, CPM e indicadores de participação de impressões, conforme os campos efetivamente disponibilizados. A interpretação ocorrerá no contexto do objetivo da campanha: métricas de campanhas com finalidades diferentes não serão tratadas como diretamente equivalentes.

Regras de negócio, sazonalidade, capacidade de atendimento e limites de variação de orçamento serão explicitados antes da construção de cenários. Os cenários mínimo, ideal e agressivo, quando aplicáveis, serão cálculos direcionais e reproduzíveis baseados em parâmetros declarados e valores observados. Eles não projetarão matrícula, não garantirão retorno e não ocultarão conflitos entre regras ou limitações dos dados. Indicadores e métricas de desempenho devem ser interpretados de acordo com os objetivos organizacionais e com o contexto de cada ação de marketing digital (Saura; Palos-Sánchez; Suárez, 2017); em campanhas de busca, a multiplicidade de configurações também torna inadequada uma decisão apoiada em uma única métrica (Martins, 2019).

2.4.6 Auditoria, reprodutibilidade e limites de atribuição

Cada resultado exibido deverá poder ser reconstituído a partir de sua fonte, período, regra de transformação e fórmula. Os arquivos de entrada processados, as constantes de cálculo e os resultados intermediários serão versionados no repositório real, permitindo revisão do caminho que levou a cada indicador ou cenário. A reprodutibilidade é parte do procedimento analítico, pois permite conferir os resultados computacionais e suas condições de produção (Peng, 2011).

O método declarará limites de atribuição. Impressão, clique, conversão de plataforma, conversa, lead e matrícula não serão tratados como sinônimos. Quando houver apenas dados agregados, a análise poderá descrever associação entre etapas do funil, mas não atribuir uma matrícula a uma campanha ou a um canal específico. Essa ressalva será exibida junto às interpretações que dependem desses dados, pois as escolhas de atribuição alteram a leitura do retorno de investimentos em busca paga (Li et al., 2016).

2.4.7 Protocolo experimental de aprendizagem de máquina sobre conteúdo orgânico da Meta

Avaliará a disponibilidade de relatórios históricos de conteúdo orgânico da Meta. Havendo volume e variáveis adequados, definirá variável-alvo, atributos disponíveis antes da publicação, divisão temporal entre treino e teste, referência determinística, modelos comparados e métricas de avaliação. O código, os dados autorizados, o treinamento, os testes e o relatório técnico detalhado serão mantidos no repositório real da solução; este repositório acadêmico registrará apenas o método e resultados sanitizados ou fictícios necessários à

demonstração. O protocolo distinguirá explicitamente cálculos por fórmula de modelos treinados com exemplos históricos, conforme a caracterização de aprendizagem de máquina apresentada por Jordan e Mitchell (2015), e registrará o emprego do modelo como aplicação de IA em marketing, nos termos discutidos por De Mauro, Sestino e Bacconi (2022).

2.4.8 Interpretação assistida por IA e engenharia de memória/contexto

Modelos de linguagem de alta capacidade serão utilizados somente como camada de interpretação assistida. Poderão organizar evidências, comparar cenários e formular explicações preliminares a partir de indicadores e resultados já calculados. Essa atividade não será apresentada como aprendizagem de máquina nem como evidência empírica independente. Agentes baseados em modelos de linguagem combinam recursos como planejamento, memória e uso de ferramentas, mas requerem cuidados de avaliação e confiabilidade (Wang et al., 2024).

A engenharia de memória/contexto restringirá o material disponível ao agente a documentos versionados, dados confiáveis, fórmulas, resultados calculados ou estimados e referências verificadas. Cada explicação ou recomendação deverá apontar o dado, período, cálculo, estimativa ou fonte que a fundamenta. Saídas sem base rastreável, que inventem métricas ou que ultrapassem os limites de atribuição declarados, não serão utilizadas.

2.4.9 Construção do protótipo e arquitetura da interface

A construção do protótipo separará a preparação local dos dados, os artefatos confiáveis usados na demonstração e a camada de apresentação web. Essa separação evita que a interface acadêmica dependa de contas de anúncios, credenciais ou integrações operacionais em tempo de execução. A escolha final de tecnologias será registrada antes da implementação; como referência técnica, a arquitetura web poderá adotar componentes React e recursos de renderização no servidor com Next.js, abordagem descrita por Thakkar (2020) para aplicações web baseadas em React.

O desenho do dashboard será orientado pela finalidade analítica de cada visão, com indicadores, filtros, comparações e avisos de limitação apresentados de maneira coerente. Padrões de design de dashboards auxiliam a discutir escolhas de organização visual, interação

e informação exibida (Bach et al., 2023). A implementação deverá manter a origem e o período dos dados visíveis, além de diferenciar valores observados, cálculos determinísticos e estimativas.

2.4.10 Interface web e validação da solução

A interface web será desenvolvida como meio de apresentação dos resultados analíticos, e não como substituta do processo de análise. Ela deverá mostrar indicadores, cenários, período de referência, fonte, limitações de atribuição e, quando existir modelo validado, diferenciar explicitamente valores observados de estimativas. Essa apresentação permitirá que os participantes compreendam o que está sendo medido antes de discutir possíveis decisões.

A validação ocorrerá com profissionais da instituição parceira, por meio de apresentação orientada do protótipo e registro das observações recebidas sobre compreensão, utilidade e pontos de melhoria. Técnicas de pesquisa de experiência do usuário apoiam a identificação de necessidades e a avaliação de serviços de informação (Pinheiro; Dias, 2023). O relatório registrará as contribuições efetivamente recebidas, sem antecipar aceitação, melhoria de desempenho ou alteração de decisões pela instituição.

2.5 RESULTADOS PRELIMINARES: SOLUÇÃO INICIAL

Nesta fase, a solução inicial é concebida como uma plataforma analítica independente do ambiente operacional da instituição. Seu objetivo não é automatizar decisões de orçamento, mas reunir uma cadeia verificável que parte dos dados autorizados, aplica regras explícitas e apresenta resultados com contexto suficiente para discussão pela gestão. A primeira versão deverá operar apenas com dados fictícios ou confiáveis e não manterá conexão com contas de anúncios, CRM ou sistema acadêmico.

A solução proposta organiza-se em quatro componentes. O primeiro prepara e padroniza os registros, preservando origem, período e granularidade. O segundo calcula indicadores determinísticos e classifica resultados como medidos, indisponíveis ou não verificáveis. O terceiro, condicionado à qualidade da base de conteúdo orgânico, treina e avalia separadamente um modelo supervisionado. O quarto apresenta indicadores, cenários, estimativas e limitações em uma interface web, mantendo distintas as informações observadas, calculadas e estimadas.

dados autorizados => inventário, limpeza e padronização => indicadores determinísticos (modelo supervisionado experimental) => interface web com origem, período, fórmulas e limitações => interpretação e avaliação pela comunidade externa

Como resultado preliminar de concepção, já estão definidos o problema que a plataforma deve apoiar, os limites de confidencialidade, a separação entre indicadores e aprendizagem de máquina e os requisitos de rastreabilidade da interface. Permanecem pendentes a construção da primeira versão executável, sua aplicação com dados fictícios ou confiáveis e a avaliação com profissionais da instituição. Antes da entrega do relatório parcial, esta seção deverá ser complementada com imagens da solução, descrição das funções implementadas, procedimento da primeira aplicação e observações efetivamente recebidas. Enquanto essas atividades não ocorrerem, o texto registra apenas a ideia da solução inicial, condição que a rubrica distingue de um protótipo já aplicado.

REFERÊNCIAS

BACH, Benjamin et al. Dashboard Design Patterns. *IEEE Transactions on Visualization and Computer Graphics*, v. 29, n. 1, p. 342-352, 2023. DOI: 10.1109/tvcg.2022.3209448. Disponível em: <https://doi.org/10.1109/tvcg.2022.3209448>. Acesso em: 26 ago. 2026.

DE MAURO, Andrea; SESTINO, Andrea; BACCONI, Andrea. *Machine learning and artificial intelligence use in marketing: a general taxonomy. Italian Journal of Marketing*, v. 2022, p. 439-457, 2022. DOI: 10.1007/s43039-022-00057-w. Disponível em: <https://doi.org/10.1007/s43039-022-00057-w>. Acesso em: 26 ago. 2026.

FOIDL, Harald et al. *Data pipeline quality: influencing factors, root causes of data-related issues, and processing problem areas for developers. Journal of Systems and Software*, v. 207, p. 111855, 2024. DOI: 10.1016/j.jss.2023.111855. Disponível em: <https://doi.org/10.1016/j.jss.2023.111855>. Acesso em: 26 ago. 2026.

GRUPO DO PROJETO INTEGRADOR. *Plano de ação do Projeto Integrador em Computação III: PIJ410-DRP14-A2026S2-T002*. São Paulo: UNIVESP, 2026. Documento interno.

JORDAN, Michael I.; MITCHELL, Tom M. *Machine learning: trends, perspectives, and prospects*. Science, v. 349, n. 6245, p. 255-260, 2015. DOI: 10.1126/science.aaa8415. Disponível em: <https://doi.org/10.1126/science.aaa8415>. Acesso em: 26 ago. 2026.

KANNAN, P. K.; LI, Hongshuang "*Alice*". *Digital marketing: a framework, review and research agenda. International Journal of Research in Marketing*, v. 34, n. 1, p. 22-45, 2017. DOI: 10.1016/j.ijresmar.2016.11.006. Disponível em: <https://doi.org/10.1016/j.ijresmar.2016.11.006>. Acesso em: 26 ago. 2026.

LEMES, Thieny de Cássio; DIAS, Marina Oliveira de Souza; OLIVEIRA, Tiago de. *Análise do uso de dashboard como ferramenta de apoio a tomada de decisão em instituições de ensino: uma revisão sistemática da literatura*. RENOTE, v. 21, n. 1, p. 281-290, 2023. DOI: 10.22456/1679-1916.134356. Disponível em: <https://doi.org/10.22456/1679-1916.134356>. Acesso em: 24 ago. 2026.

LI, Hongshuang "*Alice*"; KANNAN, P. K.; VISWANATHAN, Siva; PANI, *Abhishek*. *Attribution strategies and return on keyword investment in paid search advertising*. Marketing Science, v. 35, n. 6, p. 831-848, 2016. DOI: 10.1287/mksc.2016.0987. Disponível em: <https://doi.org/10.1287/mksc.2016.0987>. Acesso em: 26 ago. 2026.

MARTINS, Felipe. *Otimização de uma campanha publicitária na rede de pesquisa do Google Ads utilizando Teoria da Decisão Bayesiana*. 2019. Dissertação (Mestrado) – Universidade de São Paulo, São Paulo, 2019. DOI: 10.11606/d.45.2019.tde-22102019-115749. Disponível em: <https://doi.org/10.11606/d.45.2019.tde-22102019-115749>. Acesso em: 24 ago. 2026.

PENG, Roger D. *Reproducible research in computational science*. *Science*, v. 334, n. 6060, p. 1226-1227, 2011. DOI: 10.1126/science.1213847. Disponível em: <https://doi.org/10.1126/science.1213847>. Acesso em: 25 ago. 2026.

PINHEIRO, Gabriela da Silva Santos; DIAS, Célia da Consolação. *Técnicas e métodos de pesquisa de experiência do usuário (UX) para avaliação de estudo de usuários da informação. Perspectivas em Gestão & Conhecimento*, v. 13, n. 2, p. 133-148, 2023. DOI: 10.22478/ufpb.2236-417x.2023v13n2.63290. Disponível em: <https://doi.org/10.22478/ufpb.2236-417x.2023v13n2.63290>. Acesso em: 24 ago. 2026.

ROSADO, Keila Mara Lara; DIAS, Célia da Consolação. *A metodologia Design Thinking nas pesquisas científicas e a pertinência de sua apropriação pela Ciência da Informação. Encontros Bibli: Revista Eletrônica de Biblioteconomia e Ciência da Informação*, v. 29, e96222, 2024. DOI: 10.5007/1518-2924.2024.e96222. Disponível em: <https://doi.org/10.5007/1518-2924.2024.e96222>. Acesso em: 26 ago. 2026.

SAURA, José Ramón. *Using Data Sciences in Digital Marketing: framework, methods, and performance metrics*. *Journal of Innovation & Knowledge*, v. 6, n. 2, p. 92-102, 2021. DOI: 10.1016/j.jik.2020.08.001. Disponível em: <https://doi.org/10.1016/j.jik.2020.08.001>. Acesso em: 25 ago. 2026.

SAURA, José Ramón; PALOS-SÁNCHEZ, Pedro; SUÁREZ, Luis Manuel Cerdá. *Understanding the Digital Marketing Environment with KPIs and Web Analytics*. *Future Internet*, v. 9, n. 4, p. 76, 2017. DOI: 10.3390/fi9040076. Disponível em: <https://doi.org/10.3390/fi9040076>. Acesso em: 24 ago. 2026.

THAKKAR, Mohit. *Building React Apps with Server-Side Rendering: use React, Redux, and Next to build full server-side rendering applications*. Berkeley: Apress, 2020. DOI: 10.1007/978-1-4842-5869-9. Disponível em: <https://doi.org/10.1007/978-1-4842-5869-9>. Acesso em: 26 ago. 2026.

UNIVERSIDADE VIRTUAL DO ESTADO DE SÃO PAULO (UNIVESP). *Projeto pedagógico dos cursos de Bacharelado em Tecnologia da Informação, Ciência de Dados e Engenharia de Computação*. São Paulo: UNIVESP, 2020. Disponível em: <https://apps.univesp.br/manual-do-aluno/assets/PPC/ciencia-de-dados/PPC-BTI.pdf>. Acesso em: 25 ago. 2026.

UNIVERSIDADE VIRTUAL DO ESTADO DE SÃO PAULO (UNIVESP). *Projeto pedagógico do curso de Bacharelado em Ciência de Dados*. São Paulo: UNIVESP, 2026. Disponível em: <https://apps.univesp.br/manual-do-aluno/assets/PPC/ciencia-de-dados/PPC-BCD-2026.pdf>. Acesso em: 25 ago. 2026.

WANG, Lei et al. *A survey on large language model based autonomous agents*. *Frontiers of Computer Science*, v. 18, n. 6, 2024. DOI: 10.1007/s11704-024-40231-1. Disponível em: <https://doi.org/10.1007/s11704-024-40231-1>. Acesso em: 24 ago. 2026.